

Principais Ideias

- Avaliação de impacto é diferente de monitoramento.
- Buscar dar respostas a perguntas causais.
- Emprega métodos aleatorizados e/ou não aleatorizados.
- Acumulação de conhecimento sobre políticas públicas é um processo cumulativo.

Os Vários Significados de “Avaliação”

Quando	Avaliação...	Foco
Ex-ante	do Problema Teórica	O problema que se busca solucionar está bem conceituado? A teoria por trás do programa é factível?
Durante	de Processos (Monitoramento)	A implementação segue o planejado?
Ex-post	de Impacto	Os objetivos últimos foram alcançados?

Comparando Monitoramento e Avaliação de Impacto

Avaliação de processos

- Pressupõe um sistema de *monitoramento*.
- Pressupõe metas e indicadores.
- Examina a conformidade e eficácia da execução.
- Realizado concomitantemente à execução.

Avaliação de impacto (de resultados)

- Pressupõe a definição de objetivos.
- Examina mudanças nos indicadores finais.
- Atua nos estágios “finais” do monitoramento.
- Implementado seletivamente, após a execução.

Monitoramento vs. Avaliação de Impacto

Cadeia lógica típica de programas públicos

Objetivo → Insumo → Ação → Produto → Resultado → Impacto

(Eficácia: relação entre ação e produto;
Eficiência: relação entre insumos, ações e produtos;
Efetividade: relação entre resultados/impactos e objetivos.)

Monitoramento e Perguntas de Avaliação

Essas perguntas podem ser respondidas por atividades de monitoramento?

?

Identificar Relações Causais...

Exige que se determine **o que teria acontecido com os beneficiários** se o programa não tivesse existido.

Identificar Relações Causais...

Exige um **contrafactual**!

Identificando uma Relação Causal

- Não observamos a relação causal diretamente.
- Análise empírica revela *associações*.
- Associações podem (ou não) ser causais.
- Inferência causal depende de:
 - Uma definição empírica de causalidade.
 - Um desenho de pesquisa que permita inferência causal.

O Modelo Contra-Factual de Causalidade

Uma ideia simples, porém poderosa!

Uma exposição informal

- Assuma uma “causa” que pode estar presente ou não.
- Para cada observação há dois “resultados potenciais”:
 - Um com a causa presente.
 - Outro com a causa ausente.
- O efeito causal é a diferença entre resultados potenciais.
- Não observamos os dois resultados potenciais simultaneamente para as mesmas unidades.

Aplicação do Modelo Contra-Factual de Causalidade

O que é “definir um contra-factual”?

- Escolher observações que representarão o que teria acontecido sem a intervenção.

Como se define um contra-factual?

- Métodos experimentais (aleatorizados).
- Métodos quase-experimentais (não aleatorizados).

Como se usa o contra-factual?

- Compara-se os indicadores de impacto nas unidades afetadas pelo programa com os indicadores contra-factuais.

Resultados Potenciais

Um exemplo simples

Hipótese

Uma transferência direta condicionada aumenta o aprendizado escolar.

Resultados potenciais:

- Y_i^1 : Aprendizado se a criança i recebe uma transferência.
- Y_i^0 : Aprendizado se a criança i não recebe uma transferência.

Efeito causal teórico: $Y_i^1 - Y_i^0$ (mesma criança no mesmo momento)

Na prática, comparamos grupos de crianças diferentes e/ou a mesma criança no tempo.

Resultados Potenciais

Um exemplo simples

Hipótese

Uma transferência direta condicionada aumenta o aprendizado escolar.

Resultados potenciais:

- Y_i^1 : Aprendizado se a criança i recebe uma transferência.
- Y_i^0 : Aprendizado se a criança i não recebe uma transferência.

Efeito causal teórico: $Y_i^1 - Y_i^0$
(i.e., mesma criança no mesmo momento)

Modelos de Avaliação de Impacto

- **Avaliações aleatorizadas/experimentais**

Modelos de Avaliação de Impacto

- **Avaliações aleatorizadas/experimentais**
 - Avaliador manipula tratamento.

Modelos de Avaliação de Impacto

- **Avaliações aleatorizadas/experimentais**

- Avaliador manipula tratamento.
- Grupos de controle e tratamento definidos aleatoriamente.

Modelos de Avaliação de Impacto

- **Avaliações aleatorizadas/experimentais**
 - Avaliador manipula tratamento.
 - Grupos de controle e tratamento definidos aleatoriamente.
- **Avaliações não aleatorizadas / “quase experimentais”**

Modelos de Avaliação de Impacto

- **Avaliações aleatorizadas/experimentais**
 - Avaliador manipula tratamento.
 - Grupos de controle e tratamento definidos aleatoriamente.
- **Avaliações não aleatorizadas / “quase experimentais”**
 - Tratamento não é manipulado pelo avaliador.

Modelos de Avaliação de Impacto

■ Avaliações aleatorizadas/experimentais

- Avaliador manipula tratamento.
- Grupos de controle e tratamento definidos aleatoriamente.

■ Avaliações não aleatorizadas / “quase experimentais”

- Tratamento não é manipulado pelo avaliador.
- Não há aleatorização do tratamento.

A importância e a lógica da aleatorização

A importância e a lógica da aleatorização

Randomização ou Aleatorização

- Iguala todos os atributos (observáveis ou não).
- Anula todas as diferenças pré-tratamento entre os grupos.
- Permite que diferenças pós-tratamento sejam interpretadas como efeitos causais.

Várias Maneiras de Aleatorizar

- Pura no nível individual.
- Entre blocos/clusters.
- Dentro de blocos (problema político vs. *spillovers*).
- Via “escassez” (*oversubscription*).
- Início aleatorizado (*phase-in*).
- Incentivo aleatorizado (*inducement*).

Aleatorização como Referência

Mas a aleatorização é sempre uma *referência* poderosa!

Avaliações Quase-Experimentais

- Tratamento não é manipulado pelo avaliador.
- Não há aleatorização do tratamento.
- Diversos métodos buscam “simular” a aleatorização:
 - Pareamento (*matching*)
 - Diferenças em Diferenças → Painel
 - Regressão Discreta / Descontínua
 - Controle Sintético
 - Variáveis Instrumentais

Pareamento: Passo a passo

- 1 Obter os dados.
- 2 Escolher as variáveis que devem ser usadas para criar grupos equilibrados.
- 3 Escolher o algoritmo de pareamento.
- 4 Criar amostra com observações semelhantes.
- 5 Avaliar o equilíbrio.
- 6 Analisar os dados nesta nova amostra.


Pareamento (Matching)

Uma intuição

Comparar apenas casos parecidos


- Requer dados sobre tratados e muitos não tratados.
- Variáveis devem ser observadas **antes** do tratamento.
- Somente funciona para características observáveis.

A beleza do modelo de Diferenças em Diferenças (DD)



- Diferenças iniciais entre grupos: B – D

A beleza do modelo de Diferenças em Diferenças (DD)



- Diferenças iniciais entre grupos: $B - D$
- Diferenças no tempo não devidas ao tratamento: $C - D$

Diferenças em Diferenças (DD)

Comparando tendências entre grupos

- Comparar tratados com não tratados.
- Antes e depois do tratamento.
- A premissa é que a variação nos grupos seria a mesma sem o tratamento.

Discontinuidade na Regressão (RDD)

Comparando tratados e não tratados perto de um ponto de corte

- Tratamento é determinado por um critério objetivo, conhecido, e ordinal.
- Há um corte arbitrário.
- De um lado há sujeitos tratados, do outro não tratados.
- Sujeitos próximos ao corte em lados diferentes são muito parecidos, exceto pelo tratamento.

Riscos da Avaliação de Impacto

- Há incerteza associada às conclusões de avaliações.
- “Conhecimento” é um processo cumulativo.
- Nem todos os estudos devem ter peso igual.
- Intenções dos avaliadores importam (avaliações também podem ser politizadas).
- É preciso alguma *expertise* para interpretar uma avaliação.