


**Após leitura do capítulo,
você será capaz de:**

- 21.1 Reconhecer a diferença entre estudos de duas amostras e estudos de dados emparelhados e distinguir qual é apropriado a dado contexto.
- 21.2 Determinar se as condições para inferência na comparação de duas médias são satisfeitas em situações específicas.
- 21.3 Usar os procedimentos t de duas amostras para calcular o valor P para testes de significância e para calcular intervalos de confiança.
- 21.4 Usar a tecnologia para calcular intervalos e valores P para procedimentos t de duas amostras.
- 21.5 Usar o tamanho amostral e informação sobre a Normalidade de duas populações para determinar se um procedimento t de duas amostras é apropriado.
- 21.6 Usar a fórmula para os graus de liberdade para encontrar a distribuição aproximada da estatística t de duas amostras na comparação de duas médias.
- 21.7 Estabelecer as limitações do procedimento t de duas amostras combinadas e a razão pela qual ele não deve ser usado se um programa estatístico estiver disponível.
- 21.8 Explicar por que inferências sobre desvios-padrão populacionais devem ser evitados na prática básica da estatística.



Comparação de Duas Médias

No Capítulo 20, estudamos inferência para a média de uma população Normal, usando procedimentos com base na distribuição t . Na prática, o uso mais comum dos procedimentos t para uma única média populacional é com dados emparelhados, porque a maioria dos estudos de pesquisa faz comparações entre duas ou mais populações. Neste capítulo, discutimos os procedimentos t para a comparação das médias de duas populações Normais, quando temos amostras independentes dessas duas populações.

A comparação de duas populações ou dois tratamentos é uma das situações mais comuns encontradas na prática estatística. Chamamos essas situações de *problemas de duas amostras*.

Problemas de duas amostras

- O objetivo da inferência é a comparação das respostas a dois tratamentos ou a comparação das características de duas populações
- Temos uma amostra separada de cada tratamento ou de cada população.

21.1 Problemas de duas amostras

Um problema de duas amostras pode surgir de um experimento comparativo aleatorizado que divide os sujeitos aleatoriamente em dois grupos e expõe cada grupo a um tratamento diferente. A comparação de amostras aleatórias selecionadas separadamente de duas populações é também um problema de duas amostras. Diferentemente dos planejamentos de dados emparelhados estudados antes, não há qualquer emparelhamento dos indivíduos nas duas amostras. Supõe-se que as duas amostras sejam independentes e que possam ser de tamanhos diferentes. Procedimentos de inferência para dados de duas amostras diferem daqueles para dados emparelhados. A seguir, apresentamos alguns problemas típicos de duas amostras.

EXEMPLO 21.1 Problemas de duas amostras

- A fisioterapia regular ajuda na dor lombar? Um experimento aleatorizado associou pacientes com dores lombares a dois grupos: 142 receberam um exame e conselhos de um fisioterapeuta; outros 144 receberam fisioterapia regular durante até cinco semanas. Depois de um ano, a mudança em seus níveis de incapacidade (0 a 100%) foi avaliada por um médico que não sabia qual tratamento o paciente havia recebido
- Uma pesquisadora educacional aplica um teste de compreensão geral de assuntos a partir de leituras indicadas a uma amostra de estudantes que usam *tablets* em vez do tradicional livro impresso, e a uma amostra de estudantes que usam livros-texto impressos. Ela compara os escores de teste dos estudantes que usam *tablets* com os escores dos estudantes que usam os tradicionais livros-texto impressos
- Um banco deseja saber qual de dois planos de incentivo aumentará mais o uso de seus cartões de crédito. Ele ofere-

ce cada incentivo a amostras aleatórias independentes de clientes de cartão de crédito e compara as quantias debitadas no cartão durante os seis meses seguintes.

ESTATÍSTICA NO MUNDO REAL**Dirigindo enquanto jejua**

Muitos islâmicos jejuam do nascer até o pôr do sol durante o mês do Ramadan. Isso afeta a taxa de acidentes de trânsito? O jejum pode melhorar o estado de alerta, reduzindo acidentes. Ou pode causar desidratação, aumentando os acidentes. Dados da Turquia mostram um aumento estatisticamente significativo, começando duas semanas no Ramadan. Ora, como o Ramadan segue um calendário lunar, ele tem um ciclo ao longo do ano. Talvez os acidentes diminuam em um Ramadan no inverno (estado de alerta), mas aumentem durante um Ramadan no verão (jejum mais longo e desidratação). Pergunte aos estatísticos sobre essa questão e obtenha deles sua resposta favorita: precisamos de mais dados.

APLIQUE SEU CONHECIMENTO

Qual é o planejamento dos dados? Cada situação descrita nos Exercícios 21.1 a 21.4 requer inferência sobre uma média ou médias. Identifique cada uma como envolvendo (1) uma única amostra, (2) dados emparelhados ou (3) duas amostras independentes. Os procedimentos do Capítulo 20 se aplicam aos planejamentos (1) e (2). Estamos prestes a aprender os procedimentos para (3).

21.1 Postagem no Twitter. As pessoas fazem mais postagens no Twitter à medida que o número de seus seguidores aumenta? Para testar isso, pesquisadores selecionaram uma amostra aleatória de usuários do Twitter. Esses usuários foram divididos aleatoriamente em dois grupos, um grupo de tratamento e um grupo de controle. Os usuários não sabiam a qual grupo haviam sido destinados. Durante um período de 100 dias, o número de seguidores foi firmemente aumentado pelos pesquisadores para os sujeitos no grupo de tratamento. No entanto, os sujeitos desse grupo não sabiam a fonte desse aumento. Os usuários no grupo de controle foram simplesmente observados pelos pesquisadores. O número médio de postagens para cada usuário foi registrado por um período de 50 dias. Compararam-se, então, os números médios de postagens para cada grupo.

21.2 Quem é mais inteligente? Escolha uma amostra aleatória de 100 famílias, com pelo menos duas crianças de idades diferentes em cada uma. Meça os escores de QI

do primogênito e da criança mais nova em cada família. Compare o escore médio de QI de cada primogênito com o da criança mais nova.

21.3 Hambúrguer com base em vegetais. Uma nutricionista de uma escola seleciona uma amostra de estudantes em uma grande escola distrital e lhes pede que provem e classifiquem um novo hambúrguer que está sendo considerado como um item adicional no menu do almoço da escola. A nutricionista não diz aos estudantes que o novo hambúrguer é feito à base de vegetais que, supostamente, devem ter o sabor de carne. As classificações variam de -5 a 5, com -5 significando que fortemente não gostou, 0 nem gostou nem desgostou, e 5 gostou fortemente. A nutricionista testa se a classificação média é maior do que 0.

21.4 Hambúrguer com base em vegetais (continuação). Outra nutricionista seleciona uma amostra de estudantes em uma grande escola distrital e divide aleatoriamente a amostra em dois grupos. Um grupo classifica o gosto de um hambúrguer à base de vegetais, e o outro, o gosto de um hambúrguer tradicional de carne. Nenhum dos grupos sabe de que é feito o hambúrguer que prova. As classificações variam de -5 a 5, com -5 significando que fortemente não gostou, 0 nem gostou nem desgostou, e 5 gostou fortemente. A nutricionista compara as classificações médias dos dois grupos.

21.2 Comparação de duas médias populacionais

A comparação de duas populações, ou das respostas a dois tratamentos, começa com a análise de dados: faça diagramas de caixas, diagramas de ramo e folhas (para amostras pequenas), ou histogramas (para amostras maiores), e compare

as formas, os centros e as dispersões das duas amostras. O objetivo mais comum da inferência é a comparação das respostas médias ou típicas nas duas populações. Quando a análise de dados sugere que ambas as distribuições populacionais são simétricas e, especialmente, quando elas são, pelo menos, aproximadamente Normais, desejamos comparar as médias populacionais. Eis as condições para a inferência sobre médias.

Condições para inferência na comparação de duas médias

- Temos duas AAs, provenientes de duas populações diferentes. As amostras são *independentes*. Ou seja, uma amostra não tem influência sobre a outra. O emparelhamento viola a independência, por exemplo. Medimos a mesma variável resposta para ambas as amostras.
- As duas populações são *Normalmente distribuídas*. As médias e os desvios-padrão das populações são desconhecidos. Na prática, é suficiente que as distribuições tenham formas semelhantes e que os dados não tenham valores atípicos extremos.

Os procedimentos de duas amostras neste capítulo também podem ser usados para estudos que comparam as respostas a dois tratamentos. Supomos que temos dados provenientes de um experimento comparativo aleatorizado que divide aleatoriamente os sujeitos em dois grupos e expõe cada grupo a um tratamento diferente.

Chame de x_1 a variável que medimos na primeira população e de x_2 , na segunda, porque a variável pode ter distribuições diferentes nas duas populações. A seguir, apresentamos como descrevemos as duas populações:

População	Variável	Média	Desvio-padrão
1	x_1	μ_1	σ_1
2	x_2	μ_2	σ_2

Há quatro parâmetros desconhecidos: as duas médias e os dois desvios-padrão. O índice nos indica qual população um parâmetro descreve. Queremos comparar as duas médias populacionais, ou fornecendo um intervalo de confiança para sua diferença $\mu_1 - \mu_2$, ou testando a hipótese de nenhuma diferença, $H_0: \mu_1 = \mu_2$. A hipótese nula de nenhuma diferença é usada para investigar se um tratamento tem algum efeito.

Usamos as médias e desvios-padrão amostrais para estimar os parâmetros desconhecidos. Novamente, o índice nos informa de qual amostra a estatística provém. A seguir, está a notação que descreve as amostras:

População	Tamanho amostral	Média amostral	Desvio-padrão amostral
1	n_1	$\bar{x}_1$	s_1
2	n_2	$\bar{x}_2$	s_2

Para fazermos inferência sobre a diferença $\mu_1 - \mu_2$ entre as médias das duas populações, partimos da diferença $\bar{x}_1 - \bar{x}_2$ entre as médias das duas amostras.

EXEMPLO 21.2 Atividade diária e obesidade



ESTABELEÇA: as pessoas ganham peso quando absorvem mais energia dos alimentos do que gastam. James Levine e seus colaboradores da Clínica Mayo examinaram a ligação entre obesidade e gasto de energia na atividade diária.¹

Escolha 20 voluntários saudáveis que não fazem exercício. Escolha, deliberadamente, 10 que sejam magros e 10

que sejam ligeiramente obesos, mas, ainda assim, saudáveis. Coloque nos sujeitos sensores que monitorem cada movimento deles durante dez dias. A Tabela 21.1 apresenta os dados do tempo (em minutos por dia) que os sujeitos gastaram em pé ou andando, sentados ou deitados. Os magros e os obesos diferem no tempo médio que gastam em pé ou andando?

Tabela 21.1 Tempo (minutos por dia) gasto, em três posturas diferentes, por sujeitos magros e obesos

Grupo	Sujeito	De pé/Andando	Sentado	Deitado
Magro	1	511,100	370,300	555,500
Magro	2	607,925	374,512	450,650
Magro	3	319,212	582,138	537,362
Magro	4	584,644	357,144	489,269
Magro	5	578,869	348,994	514,081
Magro	6	543,388	385,312	506,500
Magro	7	677,188	268,188	467,700
Magro	8	555,656	322,219	567,006
Magro	9	374,831	537,031	531,431
Magro	10	504,700	528,838	396,962
Obeso	11	260,244	646,281	521,044
Obeso	12	464,756	456,644	514,931

(Continua)

Tabela 21.1 Tempo (minutos por dia) gasto, em três posturas diferentes, por sujeitos magros e obesos (Continuação)

Grupo	Sujeito	De pé/Andando	Sentado	Deitado
Obeso	13	367,138	578,662	563,300
Obeso	14	413,667	463,333	532,208
Obeso	15	347,375	567,556	504,931
Obeso	16	416,531	567,556	448,856
Obeso	17	358,650	621,262	460,550
Obeso	18	267,344	646,181	509,981
Obeso	19	410,631	572,769	448,706
Obeso	20	426,356	591,369	412,919

PLANEJE: examine os dados e realize um teste de hipóteses. Suspeitamos, de antemão, que os sujeitos magros (Grupo 1) sejam mais ativos do que os sujeitos obesos (Grupo 2), de modo que testamos as hipóteses

$$H_0: \mu_1 = \mu_2$$

$$H_a: \mu_1 > \mu_2$$

RESOLVA (primeiros passos): as condições para inferência são satisfeitas? Os sujeitos são voluntários, de modo que não são AASs de todos os adultos magros e de todos os ligeiramente obesos. O estudo tentou recrutar grupos comparáveis: todos tinham ocupações sedentárias, nenhum fumava ou estava tomando algum medicamento, e assim por diante. Ao estabelecermos padrões claros como esses, compensamos o fato de que não podemos, razoavelmente, conseguir AASs para um estudo tão invasivo. Não foi dito aos sujeitos que eles foram escolhidos de um grupo maior de voluntários porque não faziam exercícios ou porque eram magros ou ligeiramente obesos. Como a sua disposição em participar não está relacionada ao objetivo do estudo, vamos considerá-los como duas AASs independentes.

Um diagrama de ramo e folhas lado a lado (Figura 21.1) mostra os dados para “De pé/Andando” em detalhe. Para fazermos o gráfico, arredondamos os dados até os dez minutos mais próximos e usamos as centenas como ramos e as dezenas como folhas. As distribuições são um pouco irregulares, como esperaríamos de apenas 10 observações.

Magro	Obeso
2	6 7
7 2	3 5 6 7
4	1 1 2 3 6
8 8 6 4 1 0	5
8 1	6

FIGURA 21.1

Diagrama de ramo e folhas lado a lado dos tempos gastos andando ou em pé, para o Exemplo 21.2. Aqui, os valores estão em centenas, de modo que, por exemplo, 2|6 = 260.

Não há afastamentos claros da Normalidade, como valores atípicos extremos ou assimetria. Os sujeitos magros, como um grupo, gastam mais tempo em pé ou andando do que os sujeitos obesos. O cálculo das médias dos grupos confirma isso:

Grupo	n	Mean $\bar{x}$	Desvio-padrão s
Grupo 1 (magro)	10	525,751	107,121
Grupo 2 (obeso)	10	373,269	67,498

A diferença observada no tempo médio por dia gasto em pé ou andando é

$$\bar{x}_1 - \bar{x}_2 = 525,751 - 373,269 = 152,482 \text{ minutos}$$

Para completar o passo “Resolva”, devemos aprender os detalhes da inferência que compara duas médias.

21.3 Procedimentos *t* de duas amostras

Para avaliarmos a significância da diferença observada entre as médias de nossas duas amostras, seguimos um caminho familiar. O fato de uma diferença observada ser surpreendente depende da dispersão das observações, bem como das duas médias. Médias muito diferentes podem ocorrer apenas devido ao acaso, se as observações individuais variam bastante. Para levarmos em consideração a variação, gostaríamos de padronizar a diferença $\bar{x}_1 - \bar{x}_2$, dividindo-a por seu desvio-padrão. Esse desvio-padrão da diferença das médias amostrais é

$$\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$$

Esse desvio-padrão se torna maior quando a população se torna mais variável – isto é, quando σ_1 ou σ_2 aumentam. Torna-se menor quando os tamanhos das amostras n_1 e n_2 aumentam.

Como não conhecemos os desvios-padrão populacionais, nós os estimamos pelos desvios-padrão amostrais de nossas duas amostras. O resultado é o erro padrão, ou desvio-padrão estimado, da diferença das médias amostrais:

$$EP_{\bar{x}_1 - \bar{x}_2} = \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

Quando padronizamos a estimativa dividindo-a por seu erro padrão, o resultado é a **estatística t de duas amostras**:

$$t = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

Note que, para testes de hipóteses, $H_0: \mu_1 = \mu_2$ nos diz que $\mu_1 - \mu_2 = 0$. A estatística t tem a mesma interpretação que qualquer estatística z ou t : ela tem a forma

Estimativa do parâmetro – Valor do parâmetro sob a hipótese nula
Erro padrão da estimativa

e informa quão distante $\bar{x}_1 - \bar{x}_2 = 0$ está de $\mu_1 - \mu_2 = 0$ em unidades de desvio-padrão.

A estatística t de duas amostras tem, aproximadamente, uma distribuição t . Não tem exatamente uma distribuição t , mesmo se as populações forem exatamente Normais. Na prática, contudo, a aproximação é bem precisa. Há duas opções práticas para o uso dos procedimentos t de duas amostras:

Opção 1. Com um programa, use a estatística t com valores críticos precisos da distribuição t aproximada. Os graus de liberdade são calculados a partir dos dados, por uma fórmula complicada. Além disso, os graus de liberdade podem não ser números inteiros.

Opção 2. Sem um programa, use a estatística t com valores críticos da distribuição t com número de *graus de liberdade* igual ao menor entre $n_1 - 1$ e $n_2 - 1$. Esses procedimentos são sempre conservadores para quaisquer duas populações Normais. O intervalo de confiança tem uma margem de erro tão grande ou maior que o necessário para o nível de confiança desejado.

O teste de significância dá um valor P igual a ou maior que o verdadeiro valor P .

As duas opções são exatamente a mesma, exceto pelo número de graus de liberdade usados para os valores críticos de t e valores P . À medida que os tamanhos amostrais aumentam, os níveis de confiança e os valores P da Opção 2 se tornam mais precisos. A lacuna entre o que a Opção 2 reporta e a verdade é muito pequena, a menos que os tamanhos amostrais sejam ambos pequenos e diferentes.²

Procedimentos t de duas amostras

Extraia uma AAS de tamanho n_1 de uma população Normal com média μ_1 desconhecida, e extraia uma AAS independente de tamanho n_2 de outra população Normal com média desconhecida μ_2 . Um intervalo de confiança para $\mu_1 - \mu_2$ de nível C é dado por

$$(\bar{x}_1 - \bar{x}_2) \pm t^* \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

Aqui, t^* é o valor crítico para o nível de confiança C para a distribuição t com graus de liberdade da Opção 1 (programa) ou da Opção 2 (menor entre $n_1 - 1$ e $n_2 - 1$).

Para testar a hipótese $H_0: \mu_1 = \mu_2$, calcule a estatística t de duas amostras

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

Determine valores P a partir da distribuição t com graus de liberdade da Opção 1 (programa) ou da Opção 2 (menor entre $n_1 - 1$ e $n_2 - 1$).

EXEMPLO 21.3 Atividade diária e obesidade



Podemos, agora, completar o Exemplo 21.2.

RESOLVA (inferência): a estatística t de duas amostras que compara a média de minutos gastos em pé ou andando no Grupo 1 (magros) e no Grupo 2 (obesos) é


$$\begin{aligned} t &= \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} \\ &= \frac{525,751 - 373,269}{\sqrt{\frac{107,121^2}{10} + \frac{67,498^2}{10}}} \\ &= \frac{152,482}{40,039} = 3,808 \end{aligned}$$

FIGURA 21.2

Usando a Opção 2 conservadora, o valor P no Exemplo 21.3 vem da distribuição t com 9 graus de liberdade.

Um programa (Opção 1) dá o valor P unilateral $P = 0,0008$, baseado em $gl = 15,174$.

Sem um programa, use a Opção 2 conservadora. Como $n_1 - 1 = 9$ e $n_2 - 1 = 9$, há 9 graus de liberdade. Como H_a é unilateral, o valor P é a área à direita de $t = 3,808$, sob



a curva t_9 . A Figura 21.2 ilustra esse valor P . A Tabela C mostra que $t = 3,808$ está entre os valores críticos t^* para 0,0025 e 0,001. Assim, $0,001 < P < 0,0025$. A Opção 2 dá

$gl = 9$		
t^*	3,690	4,297
P unilateral	0,0025	0,001

A falta de atividade diária *causa* obesidade? Esse é um estudo observacional, e isso afeta nossa capacidade de tirar conclusões sobre causa e efeito. Pode ser que algumas pessoas sejam naturalmente mais ativas e, portanto, menos propensas a ganhar peso. Ou pode ser que as pessoas que ganhem peso reduzam seu nível de atividade. O estudo prosseguiu, colocando a maior parte dos sujeitos obesos em um programa de redução de peso e a maioria dos sujeitos magros em um programa supervisionado

um valor P maior (mais conservador) do que a Opção 1. Como sempre, a conclusão prática é a mesma para ambas as versões do teste.

CONCLUA: há evidência muito forte ($P = 0,0008$) de que as pessoas magras, na média, gastam mais tempo andando ou de pé do que as moderadamente obesas.

EXEMPLO 21.4 Quão mais ativas são as pessoas magras?

PLANEJE: para estimarmos quão mais ativas são as pessoas magras, damos um intervalo de confiança de 90% para $\mu_1 - \mu_2$, a diferença na média diária de minutos gastos em pé ou andando, entre os adultos magros e os obesos.

RESOLVA E CONCLUA: como no Exemplo 21.3, a Opção 2 conservadora usa 9 graus de liberdade. A Tabela C mostra que o valor crítico de t_9 é $t^* = 1,833$. Estamos 90% confiantes em que $\mu_1 - \mu_2$ esteja no intervalo

$$\begin{aligned} (\bar{x}_1 - \bar{x}_2) \pm t^* \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}} \\ = (525,751 - 373,269) \pm 1,833 \sqrt{\frac{107,121^2}{10} + \frac{67,498^2}{10}} \\ = 152,482 \pm 73,391 \\ = 79,09 \text{ a } 225,87 \text{ minutos} \end{aligned}$$

Um programa que use a Opção 1 dá o intervalo de 90% como 82,35 a 222,62 minutos, com base em t com 15,174 graus de liberdade. O intervalo da Opção 2 é maior

de superalimentação. Depois de oito semanas, os sujeitos obesos tinham perdido peso (média de 8 kg) e os sujeitos magros tinham ganhado peso (média de 4 kg). Porém, ambos os grupos mantiveram suas alocações originais de tempo às diferentes posições. Isso sugere que a alocação de tempo é biológica e influencia o peso, mais do que o contrário. Os autores observam que “Deve-se enfatizar que esse foi um estudo piloto e que os resultados precisam ser confirmados em estudos mais amplos”.

porque esse método é conservador. Ambos os intervalos são bastante grandes porque as amostras são pequenas e a variação entre indivíduos, medida pelos dois desvios-padrão amostrais, é grande. Seja qual for o intervalo que relatarmos, estaremos (pelo menos) 90% confiantes em que a diferença média nos minutos médios diários gastos em pé ou andando entre adultos magros e ligeiramente obesos estará nesse intervalo.

ESTATÍSTICA NO MUNDO REAL

Metanálise

Pequenas amostras têm grandes margens de erro. Grandes amostras são dispendiosas. Frequentemente, podemos encontrar vários estudos sobre o mesmo problema; se pudéssemos combinar seus resultados, teríamos uma grande amostra com uma pequena margem de erro. Essa é a ideia da “metanálise”. Naturalmente, não podemos apenas colocar os estudos junto devido às diferenças no planejamento e qualidade. Estatísticos têm maneiras mais sofisticadas de combinar os resultados. A metanálise tem sido aplicada a problemas que vão desde o efeito do fumo passivo até se treinamento melhora os escores SAT.

Note que no Exemplo 21.4 poderíamos ter mudado a ordem e calculado um intervalo de confiança de 90% para $\mu_2 - \mu_1$, usando $\bar{x}_2 - \bar{x}_1 = 373,269 - 525,751 = -152,482$, o que teria

alterado os sinais no intervalo de confiança, e resultando então no intervalo $-225,87$ a $-79,09$ minutos para $\mu_2 - \mu_1$. No entanto, a interpretação final seria a mesma que o intervalo para $\mu_1 - \mu_2$.

EXEMPLO 21.5 Serviço comunitário e afeição a amigos

ESTABELEÇA: universitários voluntários atuantes em trabalhos comunitários e aqueles que não atuam nesses trabalhos diferem no modo como se ligam afetivamente a seus amigos? Um estudo obteve dados de 57 alunos que atuaram em trabalho comunitário e de 17 que não atuaram. Uma das variáveis resposta era uma medida de afeição a amigos, medida pelo Inventory of Parent and Peer Attachment (escores

maiores indicam maior ligação). Em particular, a resposta é um escore que se baseia nas respostas a 25 questões. A seguir, apresentamos os resultados:³



Grupo	Condição	<i>n</i>	$\bar{x}$	<i>s</i>
1	Serviço	57	105,32	14,68
2	Sem serviço	17	96,82	14,26

PLANEJE: a pesquisadora não tinha em mente qualquer direção específica para a diferença antes de examinar os dados; logo, a alternativa é bilateral. Testaremos as hipóteses

$$H_0: \mu_1 = \mu_2$$

$$H_a: \mu_1 \neq \mu_2$$

RESOLVA: a pesquisadora diz que os escores individuais, examinados separadamente nas duas amostras, parecem razoavelmente Normais. Há um sério problema em relação à condição mais importante para que as duas amostras possam ser consideradas como AASs das duas populações de estudantes. Discutiremos isso depois de termos realizado os cálculos.


A estatística *t* de duas amostras é

$$\begin{aligned} t &= \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} \\ &= \frac{105,32 - 96,82}{\sqrt{\frac{14,68^2}{57} + \frac{14,26^2}{17}}} \\ &= \frac{8,5}{3,9677} = 2,142 \end{aligned}$$

Um programa (Opção 1) diz que o valor *P* bilateral é *P* = 0,0414.

FIGURA 21.3

O valor *P* no Exemplo 21.5. Como a alternativa é bilateral, o valor *P* é o dobro da área à direita de *t* = 2,142.



Sem um programa, use a Opção 2 para achar um valor *P* conservador. Há 16 graus de liberdade, o menor entre

$$n_1 - 1 = 57 - 1 = 56 \quad \text{e} \quad n_2 - 1 = 17 - 1 = 16$$

$$gl = 16$$

<i>t</i> *	2,120	2,235
<i>P</i> bilateral	0,05	0,04

A Figura 21.3 ilustra o valor *P*. Ache-o, comparando *t* = 2,142 com os valores críticos bilaterais da distribuição *t*₁₆. A Tabela C mostra que valor *P* está entre 0,05 e 0,04.

CONCLUA: os dados fornecem evidência moderadamente forte (*P* < 0,05) de que os alunos que se envolveram em trabalhos comunitários diferem, em média, daqueles que não se envolveram em serviços comunitários, no grau de ligação com seus amigos (e os dados sugerem que eles são mais ligados a seus amigos).

Justifica-se o teste *t* no Exemplo 21.5? Os sujeitos alunos estavam “matriculados em um curso sobre Diversidade nos EUA em uma universidade grande do Meio-Oeste”. A menos que esse curso seja exigido de todos os alunos, os sujeitos não podem ser considerados uma amostra aleatória até mesmo desse *campus*. Os alunos foram colocados nos dois grupos com base em um questionário, 39 no grupo de “nenhum serviço” e 71 no grupo de “serviço”. Os dados foram coletados a partir de uma pesquisa de acompanhamento dois anos depois; 17 dos 39 alunos no grupo de “nenhum serviço” responderam (44%), em comparação com 80% de resposta (57 entre 71) no grupo de “serviço”. A não resposta está confundida com grupo: alunos que participaram de trabalhos comunitários tinham

muito mais propensão a responder. Finalmente, 75% dos respondentes do grupo “serviço” eram mulheres, em comparação com 47% dos respondentes do grupo “nenhum serviço”. Gênero, que pode influenciar em muito a afeição a amigos, confunde-se, de modo prejudicial, com participação ou não em serviço comunitário. Os dados estão tão longe de satisfazer a condição de AAS para inferência que o teste *t* é sem sentido. Dificuldades assim são comuns em pesquisas de ciências sociais, nas quais variáveis de confundimento têm efeitos mais fortes do que o usual, quando variáveis biológicas ou físicas são medidas. Essa pesquisadora revelou honestamente as fraquezas na produção dos dados, mas deixou que os leitores decidissem se deviam, ou não, confiar em suas inferências.

APLIQUE SEU CONHECIMENTO

Nos exercícios que exigem procedimentos *t* de duas amostras, use a Opção 1, se você tiver a tecnologia que implemente aquele método. Caso contrário, use a Opção 2 (graus de liberdade como o menor entre $n_1 - 1$ e $n_2 - 1$).

21.5 Nintendo e habilidades laparoscópicas.



Na cirurgia laparoscópica, uma câmera de vídeo e vários instrumentos finos são inseridos na cavidade abdominal do paciente. O cirurgião usa a imagem da câmera de vídeo posicionada dentro do corpo do paciente para realizar o procedimento pela manipulação dos instrumentos inseridos anteriormente. Descobriu-se que o Nintendo Wii™, com sua interface de busca de movimento, replica os movimentos requeridos na cirurgia laparoscópica com mais precisão do que outros videogames. Se o treinamento com o Nintendo Wii™ pode melhorar as habilidades laparoscópicas, ele pode complementar um treinamento mais dispendioso em um simulador laparoscópico. Foram escolhidos 42 médicos residentes e todos eles foram testados em um conjunto de habilidades laparoscópicas básicas. Vinte e um foram selecionados aleatoriamente para passar por um treinamento sistemático com o Nintendo Wii™ por uma hora por dia,

cinco dias por semana, durante quatro semanas. Os 21 residentes restantes não receberam nenhum treinamento com Nintendo Wii™, e lhes foi pedido que se afastassem dos videogames durante esse período. Ao final das quatro semanas, todos os 42 residentes foram testados novamente em relação às mesmas habilidades laparoscópicas. Uma das habilidades envolvia uma remoção virtual de vesícula biliar, com várias medidas de desempenho registradas, incluindo o tempo para completar a tarefa. Eis os tempos de melhora (antes menos depois), em segundos, depois de quatro semanas, para os dois grupos:⁴

NINT

O treinamento com o Nintendo Wii™ aumenta significativamente o tempo de melhora? Siga o processo dos quatro passos como ilustrado nos Exemplos 21.2 e 21.3.

21.6 Atividade diária e obesidade.



Com base nos Exemplos 21.2 e 21.3, podemos concluir que pessoas ligeiramente obesas gastam menos tempo de pé ou andando (na média) do que pessoas magras. Há uma diferença significante entre os tempos médios que os dois grupos gastam deitados? Use o processo dos quatro passos para responder a essa questão a partir dos dados da Tabela 21.1. Siga o modelo dos Exemplos 21.2 e 21.3.

ATIVD

21.7 Nintendo e habilidades laparoscópicas (continuação).

Use os dados no Exercício 21.5 para dar um intervalo de confiança de 95% para a diferença nos tempos de melhora média entre os grupos de tratamento e de controle.

NINT

Tratamento						Controle					
291	134	186	128	84	243	21	66	54	85	229	92
212	121	134	221	59	244	43	27	77	-29	-14	88
79	333	-13	-16	71	-16	145	110	32	90	45	-81
71	77	144				68	61	44			

21.4 Exemplos de tecnologia

Os programas devem usar a Opção 1 para os graus de liberdade para fornecer intervalos de confiança e valores *P* precisos. Infelizmente, há variação no grau de qualidade da implementação da Opção 1. A Figura 21.4 mostra as saídas de uma calculadora gráfica, de três programas estatísticos e de um programa de planilhas, para o teste do Exemplo 21.3. Todos os quatro afirmam usar a Opção 1. A estatística *t* de duas amostras é exatamente como está no Exemplo 21.3, $t = 3,808$. Você pode encontrar esse valor em todas as quatro saídas. (O Minitab arredonda para 3.81; o Excel e a calculadora gráfica fornecem casas decimais adicionais.) No entanto, as diferentes tecnologias usam diferentes métodos para determinar o valor *P* para $t = 3,808$:

- CrunchIt!, JMP e a calculadora chegam à Opção 1 de forma totalmente correta. A aproximação precisa usa a distribuição *t* com aproximadamente 15,174 graus de liberdade (CrunchIt! Arredonda para 15,17). O valor *P* é $P = 0,0008$.
- Minitab usa a Opção 1, mas *trunca* o número exato de graus de liberdade para o menor inteiro mais próximo para obter valores críticos e valores *P*. Nesse exemplo, o valor exato $gl = 15,174$ é truncado para $gl = 15$, de modo que os resultados do Minitab são levemente conservadores. Isto é, o

valor *P* do Minitab (arredondado para $P = 0,001$ na saída) é ligeiramente maior que o valor *P* completo da Opção 1.

- O Excel *arredonda* o número exato de graus de liberdade para o inteiro mais próximo, de modo que $gl = 15,174$ torna-se $gl = 15$. O método do Excel coincide com o Minitab nesse exemplo. Mas, quando o arredondamento leva os graus de liberdade para o maior inteiro mais próximo, os valores *P* do Excel são ligeiramente menores do que o correto. Isto é enganoso, uma ilustração do fato de que o Excel fica abaixo do padrão como programa estatístico.



O rótulo do JMP e do Excel de que o teste supõe variâncias diferentes é um pouco enganoso. Os procedimentos *t* de duas amostras que descrevemos funcionam quer as populações tenham, quer não, a mesma variância. Há um antigo procedimento especial que funciona apenas quando as duas variâncias são iguais. Discutiremos esse método na Seção 21.7, mas não há necessidade de seu uso em problemas de duas amostras.

Embora calculadoras e programas diferentes forneçam valores *P* ligeiramente diferentes, na prática você pode aceitar o que sua tecnologia lhe dá. As pequenas diferenças em *P* não alteram a conclusão. Mesmo “entre 0,001 e 0,0025” da Opção 2 (Exemplo 21.3) é próximo o suficiente para fins práticos.








FIGURA 21.4

Procedimentos *t* de duas amostras aplicados aos dados sobre atividade e obesidade: saídas de uma calculadora gráfica, de três programas estatísticos, e de um programa de planilhas.

APLIQUE SEU CONHECIMENTO

21.8 Protetores solares. Avobenzone é um dos ingredientes ativos em vários protetores solares comercialmente disponíveis. Ele pode ser absorvido na corrente sanguínea quando o protetor solar é aplicado na pele. A Food and Drug Administration expressou preocupação com a segurança de absorção exagerada de avobenzone. Pesquisadores recrutaram



12 voluntários saudáveis para investigar a absorção de avobenzone para dois protetores solares comercialmente disponíveis: um *spray* e um creme. Os sujeitos foram associados aleatoriamente a um dos dois protetores, com

seis sujeitos a cada um. Aplicaram-se 2 mg de protetor por 1 cm² em 75% da área da superfície do corpo de cada um (área fora da roupa de banho normal), quatro vezes por dia, durante quatro dias. A quantidade de avobenzone absorvida na corrente sanguínea (em nanogramas por mililitro aplicado, ng/mL) depois de 150 horas foi então medida para cada sujeito. Eis as medidas:⁵



PROTSOLAR

Spray	2,0	1,5	1,5	1,5	0,6	0,4
Creme	0,7	0,7	0,7	0,3	0,2	0,2

A Figura 21.5 mostra a saída para o teste de duas amostras usando a Opção 1. (Essa saída é do programa CrunchIt!, que realiza a Opção 1 sem arredondamento

ou truncamento dos graus de liberdade.) Os dois protetores solares diferem na quantidade de avobenzona absorvida na corrente sanguínea depois de 150 horas?

Usando a saída na Figura 21.5, escreva um resumo, em uma sentença ou duas, incluindo t , gl , P , e uma conclusão.

FIGURA 21.5

Saída do programa CrunchIt! para o t de duas amostras, para o Exercício 21.8.

CRUNCHIT! CRUNCHIT!				
Export				
Null hypothesis:		Difference of means = 0		
Alternative hypothesis:		Difference of means is not 0		
Treatment	n	Sample Mean	Std Dev	
Spray	6	1.250	0.6156	
Creme	6	0.4667	0.2582	
df:		6.706		
Difference of means:		0.7833		
t statistic:		2.874		
P-value:		0.02499		

21.5 Robustez novamente

Os procedimentos t de duas amostras são mais robustos (menos sensíveis a afastamentos de nossa condição de Normalidade para inferência para comparação de duas médias) que os métodos t de uma amostra, particularmente quando as distribuições não são simétricas. Quando os tamanhos das duas amostras são iguais e as duas populações que estão sendo comparadas têm distribuições com formas semelhantes, os valores de probabilidades da tabela t são bastante precisos para uma grande variedade de distribuições, quando os tamanhos de amostras são tão pequenos quanto $n_1 = n_2 = 5$.⁶ Quando as duas distri-

buições populacionais têm formas diferentes, são necessárias amostras maiores.

Como uma orientação para a prática, adapte as diretrizes fornecidas no Capítulo 20 para o uso de procedimentos t de uma amostra aos procedimentos t de duas amostras, substituindo “tamanho da amostra” por “soma dos tamanhos das amostras”, $n_1 + n_2$. Essas diretrizes erram a favor da segurança, particularmente quando as duas amostras têm tamanhos iguais.  *Ao planejar um estudo de duas amostras, você deve escolher tamanhos iguais de amostras sempre que possível. Nesse caso, os procedimentos t de duas amostras são mais robustos contra a não Normalidade, e os valores conservadores da probabilidade da Opção 2 são mais precisos.*

APLIQUE SEU CONHECIMENTO

21.9 Bons odores trazem bons negócios? Os comerciantes sabem que os clientes, em geral, respondem à música de fundo. Eles respondem a odores também? Realizou-se um estudo dessa questão em uma pequena pizzaria na França, em duas noites de sábado, em maio. Em uma dessas noites, espalhou-se um perfume relaxante de lavanda por todo o restaurante. Na outra noite, não se usou

qualquer perfume. A Tabela 21.2 dá os tempos (minutos) que duas amostras de 30 clientes gastaram no restaurante e a quantidade que gastaram (em euros).⁷ As duas noites eram comparáveis em vários aspectos (clima, conta do cliente, entre outros), de modo que desejamos considerar os dados como AASs independentes das noites de sábado de primavera nesse restaurante.  **ODORES2**

Tabela 21.2 Tempo (minutos) e gasto (euros) por cliente do restaurante

Nenhum perfume		Lavanda	
Minutos	Euros gastos	Minutos	Euros gastos
103	15,9	92	21,9
68	18,5	126	18,5
79	15,9	114	22,3
106	18,5	106	21,9
72	18,5	89	18,5
121	21,9	137	24,9
92	15,9	93	18,5

(Continua)

Tabela 21.2 Tempo (minutos) e gasto (euros) por cliente do restaurante (Continuação)

Nenhum perfume		Lavanda	
Minutos	Euros gastos	Minutos	Euros gastos
84	15,9	76	22,5
72	15,9	98	21,5
92	15,9	108	21,9
85	15,9	124	21,5
69	18,5	105	18,5
73	18,5	129	25,5
87	18,5	103	18,5
109	20,5	107	18,5
115	18,5	109	21,9
91	18,5	94	18,5
84	15,9	105	18,5
76	15,9	102	24,9
96	15,9	108	21,9
107	18,5	95	25,9
98	18,5	121	21,9
92	15,9	109	18,5
107	18,5	104	18,5
93	15,9	116	22,8
118	18,5	88	18,5
87	15,9	109	21,9
101	25,5	97	20,7
75	12,9	101	21,9
86	15,9	106	22,5

- (a) O odor de lavanda encoraja os clientes a permanecer mais tempo no restaurante? Examine os dados dos tempos e explique por que eles são adequados a procedimentos t de duas amostras. Use o teste t de duas amostras para responder à questão proposta.
- (b) O odor de lavanda encoraja os clientes a gastar mais enquanto permanecem no restaurante? Examine os dados dos gastos. De que maneiras esses dados se afastam da Normalidade? Explique por que, com 30 observações, os procedimentos t são razoavelmente precisos. Use o teste t de duas amostras para responder à questão proposta.

21.10 Tempos de viagem. A American Community Survey pergunta, entre muitas outras coisas, sobre os tempos de

Carolina do Norte									
20	35	8	70	5	15	25	30	40	35
10	12	40	15	20					
Nova York									
10	15	55	20	65	50	12	20	10	10
35	50	30	45	15	10	75	40	35	60

viagem dos trabalhadores de casa para o trabalho. Eis os tempos de viagem em minutos para 15 trabalhadores na Carolina do Norte e 20 trabalhadores em Nova York, escolhidos aleatoriamente dos dados do U.S. Census Bureau.⁸  TVIAGEM

- (a) Faça diagramas de ramo e folhas para analisar as formas das distribuições. Os tempos de viagem, tanto para a Carolina do Norte quanto para Nova York, são assimétricos à direita, e os tempos de viagem para a Carolina do Norte têm um alto valor atípico. O valor atípico alto é plausível, mas também é possível que esse seja um erro. Devido à incerteza, não estamos certos se devemos removê-lo.
- (b) Suspeitamos que os tempos de viagem para Nova York sejam mais longos do que para Carolina do Norte. Os dados suportam essa suspeita?
- (c) Suponhamos que se descubra que o valor atípico nos tempos da Carolina do Norte é um erro. Os dados (com o valor atípico removido) agora apoiam a suspeita de que os tempos de viagem para Nova York são mais longos do que para a Carolina do Norte?

21.11 Ervas daninhas entre o milho. *Lamb's-quarter* é uma erva daninha comum que interfere no crescimento do milho. Um pesquisador agrícola plantou milho a uma taxa uniforme em 16 pequenos lotes e, em seguida, distribuiu manualmente a erva daninha nos lotes para permitir que um número fixo de plantas de *lamb's-quarter* crescesse em cada metro de fileira de milho. Foi evitado o crescimento de qualquer outra erva daninha. A seguir, está a produtividade do milho (*bushels* por acre) apenas para lotes experimentais controlados para terem uma erva daninha por metro de fileira e nove ervas daninhas por metro de fileira:⁹

EDMILHO

Uma erva/metro	166,2	157,3	166,7	161,1
Nove ervas/metro	162,8	142,4	162,8	162,4

Explique cuidadosamente por que um intervalo de confiança t de duas amostras para a diferença das produtividades médias pode não ser preciso.

21.12 Tempos de viagem (continuação). Use os dados do Exercício 21.10 para dar dois intervalos de confiança de 90% para a diferença nos tempos médios de viagem para Nova York e Carolina do Norte. Um intervalo deve usar todos os dados e o outro deve usar os dados com o valor atípico removido. TVIAGEM

21.6 Detalhes da aproximação t^*

A distribuição exata da estatística t de duas amostras não é uma distribuição t . Além disso, a distribuição muda, à medida que os desvios-padrão desconhecidos das populações, σ_1 e σ_2 , mudam. No entanto, uma excelente aproximação está disponível. Nós a chamamos de Opção 1 para procedimentos t .

Distribuição aproximada da estatística t de duas amostras

A distribuição da estatística t de duas amostras é muito próxima da distribuição t com número de graus de liberdade (gl) dado por

$$gl = \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2}{\frac{1}{n_1 - 1} \left(\frac{s_1^2}{n_1}\right)^2 + \frac{1}{n_2 - 1} \left(\frac{s_2^2}{n_2}\right)^2}$$

Essa aproximação é precisa quando os dois tamanhos de amostras n_1 e n_2 são maiores ou iguais a 5. Note que o numerador, $\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2$, é equivalente a $(PE_{x_1}^2 + PE_{x_2}^2)^2$.

EXEMPLO 21.6 Atividade diária e obesidade



No experimento dos Exemplos 21.2 e 21.3, os dados sobre os minutos por dia passados em pé ou andando fornecem

Grupo	n	$\bar{x}$	s
Grupo 1 (magro)	10	525,751	107,121
Grupo 2 (obeso)	10	373,269	67,498

A estatística de teste t de duas amostras calculada a partir desses valores é $t = 3,808$. O valor P unilateral é a área à direita de 3,808 sob uma curva t de densidade, como na Figura 21.2. A Opção 2 conservadora usa a distribuição t com 9 graus de liberdade. A Opção 1 chega a um valor P

muito preciso, usando a distribuição t com graus de liberdade (gl) dados por

$$gl = \frac{\left(\frac{107,121^2}{10} + \frac{67,498^2}{10}\right)^2}{\frac{1}{9} \left(\frac{107,121^2}{10}\right)^2 + \frac{1}{9} \left(\frac{67,498^2}{10}\right)^2} = \frac{2.569.894}{169.367,2} = 15,1735$$

Esses graus de liberdade aparecem na saída da calculadora gráfica na Figura 21.4. Como a fórmula é complicada, com muitas variáveis, e erros de arredondamento são prováveis, não recomendamos o cálculo de gl à mão.

O número de graus de liberdade (gl), em geral, não é um número inteiro. É sempre, no mínimo, tão grande quanto o menor entre $n_1 - 1$ e $n_2 - 1$. O número maior de graus de liberdade que resulta da Opção 1 fornece intervalos de confiança ligeiramente mais curtos e valores P ligeiramente menores do que a Opção 2 conservadora produz. Há uma distribuição t

para qualquer número positivo de graus de liberdade, embora a Tabela C contenha entradas apenas para números inteiros de graus de liberdade.

A diferença entre os procedimentos t usando as Opções 1 e 2 raramente tem importância na prática. Esse é o motivo pelo qual recomendamos a Opção 2, mais simples e conservadora, para inferência sem um computador. Com o uso de um computador, os procedimentos mais precisos da Opção 1 não causam transtornos.

⁹Esta seção pode ser omitida, a menos que você esteja usando um programa e deseje entender o que o programa faz.

APLIQUE SEU CONHECIMENTO

21.13 Intervenção comportamental na ingestão de caloria. A prevenção da obesidade infantil é importante na redução do risco futuro de doença crônica. Pesquisadores analisaram o efeito de uma intervenção comportamental envolvendo pais e crianças sobre a ingestão diária de calorias (quilocalorias/dia) pelas crianças. Os pesquisadores recrutaram 610 pares de pais/criança para o estudo. Eles associaram aleatoriamente 304 pares pais/criança ao programa de intervenção comportamental e os 306 restantes foram associados a um grupo de controle, que recebeu seis sessões de prontidão na escola durante o período do estudo. A intervenção comportamental leva a uma ingestão mais baixa de caloria comparada à do grupo de controle?¹⁰ Um programa que usa a Opção 1 fornece estes resultados resumo:

Treatment	n	Mean	Std dev	Stderr	t	df	P
Intervenção							
comportamental	304	1227	363	20.82	-3.117	603.9	<0.002
Controle	306	1323	397	22.69			

Começando pelas médias e desvios-padrão amostrais, verifique cada uma destas entradas: os erros padrão das médias, os graus de liberdade para o t de duas amostras e o valor de t .

21.14 Protetor solar. A Figura 21.5 dá a saída, para os dados dos protetores solares no Exercício 21.8, de um programa que usa a Opção 1 com o número correto de graus de liberdade. Quanto são $\bar{x}$ e s , para os dois grupos de tratamento? Começando com esses valores, encontre a estatística de teste t e seus graus de liberdade. Seu trabalho deve coincidir com a Figura 21.5.

21.15 Intervenção comportamental e ingestão de caloria (continuação). Escreva uma ou duas sentenças para resumir a comparação da ingestão diária de caloria pelas crianças do grupo de intervenção comportamental com a das crianças no grupo de controle do Exercício 21.13, como se você estivesse preparando um relatório para publicação. Use a saída no Exercício 21.13.

21.7 Evite os procedimentos t de duas amostras combinadas*

A maioria dos programas e calculadoras gráficas, incluindo os quatro ilustrados na Figura 21.4, disponibiliza uma escolha de estatísticas t de duas amostras. Uma estatística é normalmente rotulada para variâncias “desiguais” e a outra, para variâncias “iguais”. O procedimento de variâncias “desiguais” é o nosso t de duas amostras. *Esse teste é válido para variâncias populacionais iguais ou não.* A outra escolha é uma versão especial da estatística t de duas amostras que supõe que as duas populações têm variâncias iguais. Esse procedimento calcula a média (o termo estatístico é *combina*) das duas variâncias amostrais para estimar a variância comum da população. A estatística resultante é chamada de *estatística t de duas amostras combinadas*. Ela é igual à nossa estatística t se os dois tamanhos de amostras forem iguais, mas não em caso contrário. Poderíamos escolher usar a t combinada para testes e intervalos de confiança.

A estatística t combinada tem exatamente a distribuição t com $n_1 + n_2 - 2$ graus de liberdade se as duas variâncias populacionais forem, de fato, iguais, e as distribuições populacionais forem exatamente Normais. A t combinada era de uso comum até o advento de programas tornar fácil a utilização da Opção 1 para a nossa estatística t de duas amostras. Claro que, no mundo real, as distribuições não são exatamente Normais e as variâncias populacionais não são exatamente iguais. Na prática, os procedimentos t de duas amostras da Opção 1 são quase



sempre mais precisos do que os procedimentos combinados. Nosso conselho: *nunca use os procedimentos t combinados, se você tiver um programa que execute a Opção 1.*

21.8 Evite fazer inferência sobre desvios-padrão*

Duas características básicas de uma distribuição são o seu centro e a sua dispersão. Em uma população Normal, medimos o centro pela média e a dispersão pelo desvio-padrão. Usamos os procedimentos t para inferência sobre médias populacionais de populações Normais, e sabemos que os procedimentos t são, em geral, úteis também para populações não Normais. É natural recorrermos, em seguida, à inferência sobre desvios-padrão de populações Normais. Nosso conselho, nesse caso, é curto e claro: não o faça sem a orientação de um especialista.

Há métodos para inferência sobre desvios-padrão de populações Normais. O método mais comum desse tipo é o teste F para comparar os desvios-padrão de duas populações Normais.



Você encontrará esse teste nos menus da maioria dos pacotes estatísticos. *Ao contrário dos procedimentos t para médias, o teste F para desvios-padrão é extremamente sensível a distribuições não Normais.* Essa falta de robustez não melhora em amostras grandes. Ao comparar a dispersão de duas populações, é difícil, na prática, dizer se um resultado de teste significativo é evidência de dispersões populacionais desiguais, ou simplesmente sugestivo de que as populações não sejam Normais. Como esse teste é de pouco uso na prática, não daremos os detalhes.

*Esta pequena seção oferece conselhos sobre o que não fazer. Esse material não é necessário para a leitura do restante do livro.

*Esta pequena seção oferece conselhos sobre o que não fazer. Esse material não é necessário para a leitura do restante do livro.

A maior dificuldade subjacente à pouca robustez dos procedimentos de população Normal para inferência sobre dispersão já apareceu no nosso trabalho de descrição dos dados. O desvio-padrão é uma medida natural de dispersão para distribuições Normais, mas não para distribuições em geral. Na verdade, visto que distribuições assimétricas têm caudas com dispersões diferentes, nenhuma medida numérica

única funciona bem para descrever a dispersão de uma distribuição assimétrica. Resumindo, o desvio-padrão nem sempre é um parâmetro útil, e, mesmo quando o é (para distribuições simétricas), os resultados da inferência para dispersão não são confiáveis. Consequentemente, *não recomendamos a tentativa de fazer inferência sobre desvios-padrão populacionais na prática estatística básica.*¹¹



RESUMO

- Os dados em um **problema de duas amostras** são duas AAS independentes, cada uma extraída de uma população distinta.
- Testes e intervalos de confiança para a diferença entre as médias μ_1 e μ_2 de duas populações Normais começam pela diferença $\bar{x}_1 - \bar{x}_2$ entre as duas médias amostrais. Devido ao teorema limite central, os procedimentos resultantes são aproximadamente corretos para outras distribuições populacionais quando os tamanhos das amostras são grandes.
- Extraia AAS independentes de tamanhos n_1 e n_2 de duas populações Normais com parâmetros μ_1 , σ_1 e μ_2 , σ_2 . A estatística t de duas amostras é

$$t = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

- Para testes de hipótese, $H_0: \mu_1 = \mu_2$ significa $\mu_1 - \mu_2 = 0$, de modo que o numerador acima se simplifica para $\bar{x}_1 - \bar{x}_2$. A estatística t tem, aproximadamente, a distribuição t .
- Há duas escolhas para os graus de liberdade da estatística t de duas amostras. Opção 1: programas produzem valores de probabilidade precisos, usando os graus de liberdade calculados a partir dos dados. Opção 2: para procedimentos de inferência conservadores, utilize os graus de liberdade fornecidos pelo menor entre $n_1 - 1$ e $n_2 - 1$.

- O intervalo de confiança para $\mu_1 - \mu_2$ é

$$(\bar{x}_1 - \bar{x}_2) \pm t^* \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

- O valor crítico t^* da Opção 1 dá um intervalo de confiança muito próximo do nível de confiança C desejado. A Opção 2 produz uma margem de erro, pelo menos, tão grande quanto o necessário para o nível de confiança C desejado.
- Testes de significância para $H_0: \mu_1 = \mu_2$ se baseiam em

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

- Valores P calculados a partir da Opção 1 são muito precisos. Os valores P calculados a partir da Opção 2 são, pelo menos, tão grandes quanto o P verdadeiro.
- Os procedimentos t de duas amostras são bastante robustos contra afastamentos da Normalidade. As diretrizes para o uso prático são semelhantes àquelas para procedimentos t de uma amostra. Recomendamos tamanhos iguais de amostras.
- Procedimentos para inferência sobre os desvios-padrão de populações Normais são muito sensíveis a afastamentos da Normalidade. Evite inferências sobre desvios-padrão, a menos que tenha conselho de especialista.

VERIFIQUE SUAS HABILIDADES

- 21.16 O National Assessment of Educational Progress (NAEP) de 2019 aplicou um teste de matemática a uma amostra aleatória de alunos da oitava série nos Estados Unidos. O escore médio foi de 282 em um total de 500. Para dar um intervalo de confiança para o escore médio de todos os alunos da oitava série dos Estados Unidos, você usaria
- (a) um intervalo t de duas amostras.
 - (b) um intervalo t de dados emparelhados.
 - (c) um intervalo t de uma amostra.
- 21.17 Na amostra do NAEP de 2019 de alunos da oitava série dos Estados Unidos, os escores médios em matemática foram de 294 para estudantes de Massachusetts e de 276 para estudantes da Califórnia. Para verificar se essa diferença é estatisticamente significativa, você usaria
- (a) um teste t de duas amostras.
 - (b) um teste t de dados emparelhados.
 - (c) um teste t de uma amostra.

- 21.18 Considera-se que as bananas forneçam um impulso de alto carboidrato antes de uma corrida e melhorem o desempenho. Para o teste disso, 40 adultos de uma grande cidade que regularmente competem em corridas de 10K são recrutados para um estudo. Os corredores são divididos em dois grupos de 20. Ambos os grupos competem em uma corrida de 10K realizada na cidade, e seus tempos são registrados. Em seguida, um grupo é instruído a seguir sua rotina regular de preparação para a próxima corrida de 10K. O outro grupo é instruído a seguir sua dieta regular e, além disso, comer uma banana antes de correr na competição. Você compara a mudança nos tempos entre a primeira e a segunda corrida para os dois grupos e usa
- (a) um teste t de duas amostras.
 - (b) um teste t de dados emparelhados.
 - (c) um teste t de uma amostra.

- 21.19 Uma das principais razões de os procedimentos t de duas amostras serem largamente utilizados é o fato de serem bastante **robustos**. Isso significa que
- os procedimentos t não exigem que se conheçam os desvios-padrão das populações.
 - os níveis de confiança e os valores P dos procedimentos t são muito precisos, mesmo se a distribuição da população não for exatamente Normal.
 - os níveis de confiança e os valores P dos procedimentos t são muito precisos, mesmo se os graus de liberdade não forem exatamente conhecidos.
- 21.20 Crianças e adolescentes com distúrbios do espectro do autismo em geral sofrem de comportamento obsessivo-compulsivo. A droga fluoxetina ajudará a reduzir a frequência e a severidade desse comportamento em pessoas com distúrbios do espectro do autismo? Pesquisadores associaram sujeitos, com idade entre 7 e 18 anos, à fluoxetina ou a um placebo. Desses sujeitos, 54 foram associados à fluoxetina, e 55 ao placebo. Antes do tratamento e depois de 16 semanas de tratamento, os sujeitos passaram por um teste que media a frequência e a severidade do comportamento obsessivo-compulsivo. Os escores variavam de 0 a 20, com escores mais altos indicando sintomas mais graves. A mudança no escore (escore no início - escore depois de 16 semanas) foi registrada para cada participante.¹² Para a comparação da mudança média nos escores para os dois grupos, usando procedimentos t de duas amostras, com a Opção 2 conservadora, o número correto de graus de liberdade é
- 55.
 - 54.
 - 53.
- 21.21 Na Questão 21.20, as condições para inferência t de duas amostras são satisfeitas?
- Talvez: o estudo foi aleatorizado, mas precisamos observar os dados para verificar a Normalidade, porque os tamanhos amostrais são pequenos.
 - Não: escores em uma amplitude de 0 a 20 não podem ser Normais.
 - Sim: o estudo foi aleatorizado, e os grandes tamanhos amostrais tornam a condição de Normalidade desnecessária.
- 21.22 Na Questão 21.20, os pesquisadores estavam interessados em saber se a fluoxetina diminuía os sintomas (resultava em uma grande mudança no escore) comparada a um placebo. Se denotarmos por $\mu_{\text{fluoxetina}}$ a verdadeira mudança média nos escores, depois de 16 semanas, para crianças e adolescentes que tomaram fluoxetina, e por μ_{placebo} a verdadeira mudança média nos escores, depois de 16 semanas, para crianças e adolescentes que tomaram o placebo, testaremos as hipóteses
- $H_0: \mu_{\text{fluoxetina}} = \mu_{\text{placebo}}$ versus $H_a: \mu_{\text{fluoxetina}} > \mu_{\text{placebo}}$
 - $H_0: \mu_{\text{fluoxetina}} = \mu_{\text{placebo}}$ versus $H_a: \mu_{\text{fluoxetina}} \neq \mu_{\text{placebo}}$
 - $H_0: \mu_{\text{fluoxetina}} = \mu_{\text{placebo}}$ versus $H_a: \mu_{\text{fluoxetina}} < \mu_{\text{placebo}}$
- 21.23 Na Questão 21.20, os 54 sujeitos que receberam a fluoxetina tiveram uma mudança média no escore de 3,72, com desvio-padrão de 4,22; os 55 sujeitos que receberam o placebo tiveram uma mudança média no escore de 2,53, com desvio-padrão de 5,05. A estatística t de duas amostras para a comparação das médias populacionais tem valor de
- 1,336.
 - 1,19.
 - 1,336.
- 21.24 O valor P para o teste das hipóteses da questão anterior satisfaz
- $0,01 < P < 0,05$.
 - $0,05 < P < 0,10$.
 - $0,10 < P$.

EXERCÍCIOS

Os Exercícios 21.25 a 21.34 se baseiam em estatísticas resumo, mais do que em dados brutos. Essa informação é tipicamente tudo o que é apresentado em relatórios publicados. Você pode realizar procedimentos de inferência à mão a partir dos resumos. Use a Opção 2 conservadora (número de graus de liberdade igual ao menor entre $n_1 - 1$ e $n_2 - 1$) para intervalos de confiança t de duas amostras e valores P . Você deve acreditar que os autores compreenderam as condições para a inferência e verificaram se elas se aplicavam. Isto nem sempre é verdade.



- 21.25 **As mulheres falam mais que os homens?** Coloque em estudantes homens e mulheres aparelhos que registrem, secretamente, os sons para 30 segundos aleatórios em cada período de 12,5 minutos, durante dois dias. Conte as palavras que cada sujeito diz durante cada período de gravação e, a partir disso, estime quantas palavras por dia cada sujeito fala. O relatório publicado inclui uma tabela que dá o resumo para seis desses estudos.¹³ Eis dois desses

Estudo	Tamanho amostral		Número médio estimado e DP de palavras faladas por dia	
	Mulheres	Homens	Mulheres	Homens
1	56	56	16.177 (7.520)	16.569 (9.108)
2	27	20	16.496 (7.914)	12.867 (8.343)

Supõe-se que os leitores entendam que, por exemplo, as 56 mulheres no primeiro estudo tinham $\bar{x} = 16.177$ e $s = 7.520$. É comum pensar que as mulheres falam mais do que os homens. Alguma das duas amostras corrobora essa ideia? Para cada estudo:

- estabeleça hipóteses em termos das médias populacionais para os homens (μ_M) e mulheres (μ_F).
 - encontre a estatística t de duas amostras.
 - quantos graus de liberdade a Opção 2 usa para obter um valor P conservador?
 - compare seu valor de t com os valores críticos na Tabela C. O que você pode dizer do valor P do teste?
 - O que você conclui dos resultados desses dois estudos?
- 21.26 **Álcool e tonteira.** Homens saudáveis, com idade entre 21 e 35 anos, foram destinados aleatoriamente a um de dois grupos: metade recebeu 0,82 grama de álcool por quilograma de peso corporal; metade recebeu um placebo. Os participantes tiveram, então, 30 minutos para ler 34 páginas de *Guerra e Paz*, de Tolstoy (começando no Capítulo 1, com cada página contendo aproximadamente 22 linhas de texto). A cada dois ou três minutos, pedia-se aos participantes que indicassem se estavam ficando tontos. Registrou-se a proporção de vezes que cada participante indicava estar ficando tonto. A tabela que segue resume dados sobre a

proporção de episódios de tonteira.¹⁴ (O relatório do estudo deu o erro padrão da média $s/\sqrt{n}$ abreviado como EPM, em lugar do desvio-padrão s .)



Teymaz Valley

Grupo	n	$\bar{x}$	EPM
Álcool	25	0,25	0,05
Placebo	25	0,12	0,03

- Quais são os dois desvios-padrão amostrais?
- Quantos graus de liberdade a Opção 2 conservadora usa para os procedimentos t de duas amostras para essas amostras?
- Usando a Opção 2, forneça um intervalo de confiança de 95% para a diferença média entre os dois grupos.
- Um teste da hipótese nula, usando a Opção 2, de nenhuma diferença entre as duas médias dos grupos contra a alternativa bilateral, seria significativa no nível 0,05? Note que, como no caso do Exercício 17.42, você pode realizar um teste bilateral no nível $\alpha = 1 - C$, da hipótese nula $H_0: \mu_1 = \mu_2$, a partir de um intervalo de confiança de nível C para $\mu_1 - \mu_2$, rejeitando H_0 se $\mu_1 - \mu_2$ estiver fora do intervalo.

21.27 Humor e comida Em um estudo dos efeitos do humor sobre a avaliação de comida nutricional, 208 sujeitos foram associados aleatoriamente a ler uma história feliz (para induzir um humor positivo), ou a um grupo de controle (sem história, humor neutro). Pediu-se, então, aos sujeitos, que avaliassem suas atitudes em relação a certa comida, em uma escala de nove pontos, com números mais altos indicando uma atitude mais positiva em relação à comida. A tabela a seguir resume os dados sobre a classificação de atitude:¹⁵

Grupo	n	$\bar{x}$	s
Humor positivo	104	4,30	2,05
Humor neutro	104	5,50	1,74

- Quais são os erros padrão para as médias amostrais dos dois grupos?
- Quantos graus de liberdade a Opção 2 conservadora usa para os procedimentos t de duas amostras para esses dados?
- Teste a hipótese nula de nenhuma diferença entre as médias dos dois grupos contra a alternativa bilateral.

Use os graus de liberdade da parte (b). Qual é a conclusão do teste de hipótese?

21.28 Filhos únicos são mais narcisistas? Pesquisadores analisaram se é verdade o estereótipo de que filhos únicos são mais narcisistas do que crianças com irmãos. Como parte do estudo, os pesquisadores compararam as percepções de pessoas que são filhos únicos com as de pessoas que têm irmãos. Formou-se um painel representativo de 556 pessoas classificadas como “uma típica criança filho único”, com o uso do teste Narcissistic Admiration and Rivalry Questionnaire Short Scale. Do painel de 556 pessoas, 105 eram filhos únicos e 451 eram pessoas que tinham irmãos. Eis os resumos dos escores de admiração para ambos os grupos:¹⁶

Grupo	Tamanho amostral	Média	Desvio-padrão
Filho único	105	3,50	1,03
Irmãos	451	3,55	0,98

Há alguma evidência de que o escore médio de admiração de uma “típica criança filho único”, como classificada pela população de filhos únicos, seja diferente do escore médio de admiração de uma “típica criança filho único” classificada pela população de pessoas que têm irmãos?

21.29 Filhos únicos são mais narcisistas? Pesquisadores analisaram se é verdade o estereótipo de que filhos únicos são mais narcisistas do que crianças com irmãos. Um painel representativo de 1.810 pessoas se submeteu ao teste Narcissistic Admiration and Rivalry Questionnaire Short Scale. Dessas 1.810 pessoas, 233 eram filhos únicos e 1.577 tinham irmãos. Eis os resumos dos escores de admiração para ambos os grupos:¹⁷

Grupo	Tamanho amostral	Média	Desvio-padrão
Filho único	233	1,95	1,04
Irmãos	1.577	2,06	1,11

Há evidência de que o escore médio de admiração de uma criança “típico filho único” como classificada pela população de filhos únicos seja menor do que o escore de admiração de uma criança “típico filho único” classificada pela população de pessoas que têm irmãos?

21.30 Altura e a grande visão. Quarenta e seis estudantes de faculdade foram divididos aleatoriamente em dois grupos de tamanho 23. A um grupo pediu-se que se imaginassem no último andar de um alto edifício (de onde se tinha uma bela vista do entorno do prédio), e ao outro, no andar mais baixo do prédio. Pediu-se, então, aos participantes que escolhessem entre um trabalho que exigisse mais orientação detalhada *versus* um trabalho que exigisse mais orientação geral, de grande visão. Eles classificaram suas preferências de trabalho em uma escala de 11 pontos, com números mais altos correspondendo a maior preferência pelo trabalho de grande visão. Eis o resumo das estatísticas:¹⁸

Grupo	Tamanho do grupo	Média	Desvio-padrão
Baixo	23	4,61	3,08
Alto	23	6,68	3,45

- Quantos graus de liberdade você usaria nos procedimentos t de duas amostras pelo procedimento

conservador para comparar os grupos do andar mais alto e do andar mais baixo?

- (b) Qual é a estatística de teste t de duas amostras para a comparação das classificações médias de preferência de trabalho para os dois grupos?
- (c) Teste a hipótese nula de nenhuma diferença entre as duas médias populacionais contra a alternativa bilateral. Use sua estatística da parte (b) com os graus de liberdade da parte (a).

21.31 Concussões e tamanho do cérebro. Qual é o efeito de concussões no cérebro? Pesquisadores mediram os tamanhos dos cérebros (volume do hipocampo, em microlitros) de 25 jogadores de futebol de faculdade com uma história de diagnóstico clínico de concussão e de 25 jogadores de futebol de faculdade sem história de concussão. Eis as estatísticas resumo:¹⁹

Grupo	Tamanho do grupo	Média	Desvio-padrão
Concussão	25	5784	609,3
Sem concussão	25	6489	815,4

- (a) Há evidência de uma diferença no tamanho médio do cérebro entre os jogadores de futebol com história de concussão e aqueles sem concussões?
- (b) Os pesquisadores nesse estudo afirmaram que os participantes eram “casos consecutivos de atletas saudáveis da National Collegiate Athletic Association Football Bowl Subdivision Division I, com ($n = 25$) ou sem ($n = 25$) um histórico de diagnóstico clínico de concussão ... entre junho de 2011 e agosto de 2013” em um instituto de pesquisa psiquiátrica nos Estados Unidos especializado em neuroimagem, entre jogadores de futebol de faculdades. Qual efeito tem essa informação sobre sua conclusão na parte (a)?

21.32 Treinamento e escores SAT. Empresas de treinamento afirmam que seus cursos podem elevar os escores SAT de alunos do Ensino Médio. É claro que alunos que fazem outra vez o SAT, sem pagar por treinamento, geralmente também elevam seus escores. Uma amostra aleatória de alunos que fizeram o SAT duas vezes tinha 427 alunos que treinaram e 2.733 que não receberam treinamento.²⁰ A partir de seus escores em matemática na primeira e na segunda tentativa, temos estas estatísticas resumo:

	n	Tentativa 1		Tentativa 2		Ganho	
		$\bar{x}$	s	$\bar{x}$	s	$\bar{x}$	s
Com treinamento	427	521	100	561	100	40	58
Sem treinamento	2733	505	101	527	101	22	50

As estatísticas resumo para Ganho se baseiam nas mudanças nos escores dos estudantes individuais. Vamos primeiro perguntar se os alunos que foram treinados aumentaram significativamente seus escores.

- (a) Você poderia usar a informação dada na linha “Com treinamento” para realizar um teste t de duas amostras

que compare a Tentativa 1 e a Tentativa 2 para alunos treinados, ou um teste t de dados emparelhados usando o “Ganho”. Qual é o teste correto? Por quê?

- (b) Faça o teste apropriado. O que você conclui?
- (c) Forneça um intervalo de confiança de 99% para o ganho médio de todos os alunos que são treinados.

21.33 Treinamento e escores SAT (continuação). O que realmente desejamos saber é se a melhora dos alunos treinados é superior à melhora dos alunos não treinados e, se houver qualquer vantagem, se ela é grande o suficiente para valer a pena o investimento. Use a informação do exercício anterior para responder as perguntas.

- (a) Há boa evidência de que os alunos treinados ganharam mais pontos em média do que os não treinados?
- (b) Quanto a mais os alunos treinados ganham em média? Forneça um intervalo de confiança de 99%.
- (c) Com base em seu trabalho, qual é a sua opinião: você acha que vale a pena pagar cursos de treinamento?

21.34 Treinamento e escores SAT: crítica. Os dados que você usou nos dois problemas anteriores são provenientes de uma amostra aleatória de alunos que fizeram o SAT duas vezes. A taxa de resposta foi de 63%, o que é bastante bom para pesquisas não governamentais, de modo que vamos aceitar que os respondentes, de fato, representem todos os alunos que fizeram o exame duas vezes. Entretanto, não podemos estar certos de que o treinamento realmente *levou* os alunos treinados a obter um ganho maior do que os alunos não treinados. Explique brevemente, mas com clareza, por que isso acontece.

21.35 Vendas de eletrodomésticos. Uma empresa de pesquisa fornece aos fabricantes estimativas das vendas de seus produtos a partir de amostras das lojas. Os gerentes de *marketing* sempre olham as estimativas de vendas e ignoram o erro amostral. Uma AAS de 50 lojas nesse mês mostra vendas médias de 41 unidades de um eletrodoméstico particular, com desvio-padrão de 11 unidades. Durante o mesmo mês, no ano anterior, uma amostra de 52 lojas forneceu vendas médias de 38 unidades do mesmo eletrodoméstico, com desvio-padrão de 13 unidades. Um aumento de 38 para 41 é um crescimento de 7,9%. O gerente está feliz porque as vendas subiram 7,9%.

- (a) Dê um intervalo de 95% para a diferença no número médio de unidades desse eletrodoméstico vendidas nas lojas de varejo.
- (b) Explique, em linguagem que os gerentes possam entender, por que eles não podem estar confiantes de que as vendas subiram em 7,9% e, de fato, podem ter caído.

21.36 Duas estratégias de mercado. As companhias de cartão de crédito ganham uma porcentagem da quantia debitada em seus cartões de crédito, porcentagem paga pelas lojas que aceitam o cartão. Uma companhia de cartão de crédito compara duas propostas para aumentar a quantia que seus clientes debitam em seus cartões de crédito. A Proposta 1 oferece eliminar a taxa anual para clientes que debitam US\$ 1.800 ou mais em seus cartões durante o ano. A Proposta 2 oferece uma pequena porcentagem do total da quantia debitada como um retorno pecuniário, ao final do ano. A companhia de cartão de crédito oferece cada proposta a uma amostra de 100 de seus atuais clientes. Ao final do ano, registra-se a quantia total debitada por cada cliente. A seguir, as estatísticas resumo.

Grupo	<i>n</i>	$\bar{x}$	<i>s</i>
Proposta 1	100	US\$ 1.319	US\$ 261
Proposta 2	100	US\$ 1.372	US\$ 274

- (a) Os dados mostram uma diferença significativa entre as quantias médias debitadas pelos clientes a quem foram oferecidos os dois planos propostos? Dê as hipóteses nula e alternativa, e calcule a estatística *t* de duas amostras. Obtenha o valor *P*, usando a Opção 2. Estabeleça sua conclusão prática.
- (b) As distribuições das quantias debitadas nos cartões de crédito são assimétricas à direita. No entanto, valores atípicos são evitados pelos limites que as companhias de cartões de crédito impõem sobre os saldos de crédito. Você acha que a assimetria ameaça a validade do texto que você usou na parte (a)? Explique sua resposta.

Os Exercícios 21.37 a 21.46 incluem dados reais. Para aplicar os procedimentos *t* de duas amostras, use a Opção 1 se você dispõe de um programa que implemente aquele método. Caso contrário, use a Opção 2.

21.37 Melhorando suas gorjetas. Pesquisadores deram 40 cartões a uma garçonete em um restaurante italiano em Nova Jersey. Antes de entregar a conta a cada cliente, a garçonete escolhia aleatoriamente um cartão e escrevia na conta a mesma mensagem que estava no cartão. Vinte dos cartões tinham a mensagem "O tempo será realmente bom amanhã. Espero que você o aproveite!" Os outros 20 cartões continham a mensagem "O tempo não será bom amanhã. Espero que você o aproveite mesmo assim!" Depois que os clientes saíram, a garçonete registrou a quantidade da gorjeta (em percentual da conta) antes das taxas. Eis as gorjetas para os que receberam a mensagem de tempo bom:²¹

20,8 18,7 19,9 20,6 21,9 23,4 22,8 24,9 22,2 20,3
24,9 22,3 27,0 20,5 22,2 24,0 21,2 22,1 22,0 22,7

As gorjetas dos clientes que receberam a mensagem de mau tempo são

18,0 19,1 19,2 18,8 18,4 19,0 18,5 16,1 16,8 14,0
17,0 13,6 17,5 20,0 20,2 18,8 18,0 23,2 18,2 19,4

- (a) Faça diagramas de ramo e folhas ou histogramas de ambos os conjuntos de dados. Como as distribuições são razoavelmente simétricas, sem valores atípicos extremos, os procedimentos *t* funcionarão bem.
- (b) Há boa evidência de que as duas mensagens diferentes produzam gorjetas percentuais diferentes? Estabeleça as hipóteses, realize um teste *t* de duas amostras e relate suas conclusões.

21.38 Bons odores trazem bons negócios? No Exercício 21.9, você examinou os efeitos do odor de lavanda sobre o comportamento dos clientes de um pequeno restaurante. Lavanda é um odor relaxante. Os pesquisadores analisaram também os efeitos dos odores de limão, que é estimulante. O planejamento do estudo está descrito no Exercício 21.9. Aqui, apresentamos os tempos, em minutos, que os clientes gastaram no restaurante quando nenhum odor estava presente:

103 68 79 106 72 121 92 84 72 92
85 69 73 87 109 115 91 84 76 96
107 98 92 107 93 118 87 101 75 86

Quando estava presente o odor de limão, os clientes ficaram por estes tempos:

78 104 74 75 112 88 105 97 101 89
88 73 94 63 83 108 91 88 83 106
108 60 96 94 56 90 113 97

- (a) Examine ambas as amostras. Parece que o uso de procedimentos *t* de duas amostras seja justificável? As médias amostrais sugerem que um odor de limão mude o tempo médio de permanência?
- (b) O odor de limão influencia no tempo que os clientes permanecem no restaurante? Estabeleça hipóteses, realize um teste *t* e relate suas conclusões.

21.39 Melhorando suas gorjetas (continuação). Use os dados no Exercício 21.37 para fornecer um intervalo de confiança de 95% para a diferença entre as gorjetas percentuais médias para as duas diferentes mensagens.

21.40 O poder do pensamento positivo? A maneira como a imprensa relata o futuro econômico afeta o mercado de ações? Para investigar isso, pesquisadores analisaram o artigo mais longo sobre condições econômicas da página de rosto da seção Dinheiro do *USA Today*, de um dia da semana escolhido aleatoriamente, de cada semana entre agosto de 2007 a junho de 2009. Os artigos eram classificados em relação a quão positivos ou negativos eram sobre o futuro econômico. Para cada semana, a mudança na Dow Jones Industrial Average (valor médio DJIA na semana anterior ao lançamento do artigo menos a média na semana em que o artigo apareceu) era calculada. Valores positivos da mudança indicam que a DJIA aumentou.²² Eis as mudanças na DJIA correspondentes a artigos muito positivos:

-325 -200 -225 -75 -25 25 50
225 25 -325 -250 200 250 75

Aqui, as mudanças nos valores da DJIA correspondentes a artigos muito negativos:

150 300 225 125 -175 -225 -375
-175 0 125 175 475

Há boa evidência de que a DJIA tenha desempenho diferente depois de artigos muito positivos do que depois de artigos muito negativos?

- (a) As médias amostrais sugerem que haja uma diferença na mudança de DJIA depois de artigos muito positivos versus artigos muito negativos?
- (b) Faça diagramas de ramo e folhas para ambas as amostras. Há afastamentos óbvios da Normalidade?
- (c) Teste a hipótese $H_0: \mu_1 = \mu_2$ contra a alternativa bilateral. O que você conclui a partir da parte (a) e do resultado do seu teste?
- (d) Entre uma quantidade de fatores que se afirma terem disparado a crise econômica de 2007 a 2009, um foi

a “cultura da irresponsabilidade” na maneira como o futuro era descrito na imprensa. Os dados fornecem alguma evidência de que os artigos negativos na imprensa contribuíram para um desempenho fraco da DJIA?

- 21.41 Papel ou tablet?** Duzentos e trinta e um estudantes foram associados aleatoriamente a ler, em forma digital ($n = 119$), ou em forma de papel ($n = 112$), versões de artigo sobre liderança. Depois, os estudantes faziam um teste de 10 itens de múltipla escolha para verificar a precisão da memória.²³ O conjunto de dados MEMÓRIA dá os escores para todos os estudantes.

MEMORIA

- As médias amostrais sugerem que haja uma diferença nos escores médios de memória entre os dois grupos?
- Faça diagramas de ramo e folhas para ambas as amostras. Há algum afastamento óbvio da Normalidade?
- Teste a hipótese $H_0: \mu_{\text{tablet}} = \mu_{\text{papel}}$ contra a alternativa unilateral de que os estudantes que leem a versão em papel têm escores de memória mais altos do que os que leem a versão no tablet. O que você conclui da parte (a) e do resultado do seu teste?

- 21.42 Quão grande é a diferença?** Continue seu trabalho do Exercício 21.40. Um pesquisador deseja saber quão grande é a diferença na mudança na DJIA depois de artigos com um olhar econômico positivo em comparação a artigos com um olhar econômico negativo. Dê um intervalo de confiança de 90% para a diferença na mudança média na DJIA.

DJIA

- 21.43 As mulheres falam mais do que os homens? Outro estudo.** O Exercício 21.25 descreveu uma série de seis estudos que investigavam o número de palavras que mulheres e homens falavam por dia, e dá resultados de dois desses estudos. Aqui estão os resultados de outros desses estudos. Os números estimados de palavras faladas por dia para 27 mulheres são

PALAVRAS

15.357	13.618	9.783	26.451	12.151	8.391	19.763
25.246	8.427	6.998	24.876	6.272	10.047	15.569
39.681	23.079	24.814	19.287	10.351	8.866	10.827
12.584	12.764	19.086	26.852	17.639	16.616	

Os números estimados de palavras faladas por dia para 20 homens são

28.408	10.084	15.931	21.688	37.786	10.575	12.880
11.071	17.799	13.182	8.918	6.495	8.153	7.015
4.429	10.054	3.998	12.639	10.974	5.255	

O estudo fornece boa evidência de que as mulheres falam mais do que os homens, na média?

- Faça diagramas de ramo e folhas para ambas as amostras. Há desvios óbvios em relação à Normalidade? A despeito desses desvios da Normalidade, é seguro o uso dos procedimentos t . Explique.
- Teste a hipótese $H_0: \mu_1 = \mu_2$ contra a alternativa unilateral de que o número médio de palavras por dia para mulheres (μ_1) é maior do que o número médio de palavras por dia para os homens (μ_2). O que você conclui?

Os pássaros aprendem a hora de procriar? O chapim-azul come lagartas. Os pássaros gostariam de ter por perto muitas lagartas, quando fossem alimentar seus filhotes, mas eles procriam antes do pico da estação das lagartas. Os pássaros regulam o tempo para procriação com base no suprimento de lagartas do ano anterior? Pesquisadores alocaram ao acaso sete pares de pássaros para receber uma suplementação da provisão natural de lagartas enquanto estivessem alimentando seus filhotes, e outros seis pares para servirem como grupo de controle, que contariam apenas com a provisão natural de alimento. No ano seguinte, eles registraram o número de dias transcorridos entre o pico de lagartas e a procriação.²⁴ Os Exercícios 21.44 a 21.46 se baseiam nesse experimento.



schmudel/iStock

- 21.44 A aleatorização produziu grupos semelhantes?** Primeiro, compare os dois grupos no primeiro ano. A única diferença entre eles deveria ser o efeito da chance da alocação aleatória. O relatório do estudo diz que, “No ano experimental, o grau de sincronização [momento de procriação com suprimento de lagartas] não foi diferente para as fêmeas com suplemento de alimento e as do grupo de controle”. Para essa comparação, o relatório fornece $t = -1,05$. Que tipo de estatística t (emparelhada ou de duas amostras) é esse? Quais são os graus de liberdade dessa estatística? Mostre que esse t conduz à conclusão citada.

- 21.45 O tratamento surtiu algum efeito?** Os pesquisadores esperavam que o grupo de controle ajustasse a data de procriação no ano seguinte, enquanto o grupo bem alimentado, que recebera suplemento, não teria razão para mudar. O relatório prossegue: “mas, no ano seguinte, as fêmeas que receberam o suplemento alimentar estavam mais fora de sincronia com o pico das lagartas do que as do grupo de controle”. Estes são os dados (dias após o pico de lagartas):

REPROD

Controle	4,6	2,3	7,7	6,0	4,6	-1,2	
Suplementado	15,5	11,3	5,4	16,5	11,3	11,4	7,7

Faça um teste t e mostre que ele leva à conclusão citada.

- 21.46 Comparação ano a ano.** Em vez de comparar os dois grupos em cada ano, poderíamos comparar o comportamento de cada grupo no primeiro e no segundo ano. O relatório do estudo diz que “Nossa predição principal era de que as fêmeas que recebessem alimento adicional quando estivessem com filhotes pequenos não mudariam a data de pôr os ovos no ano seguinte, enquanto as do grupo de controle, que (em nossa área) procriaram muito tarde no primeiro ano, adiantariam as datas de pôr os ovos no segundo ano”. A comparação dos dias após o pico de lagartas nos Anos 1 e 2 forneceu $t = 0,63$ para o grupo de controle e $t = -2,63$ para o grupo com suplemento. Essas são estatísticas t de dados emparelhados ou de duas amostras? Quais são os graus de liberdade para cada t ? Mostre que esses valores de t não estão de acordo com a predição.

Os exercícios restantes pedem que você responda a questões a partir dos dados, sem que os detalhes lhe sejam fornecidos. O enunciado do exercício lhe dá o passo **Estabeleça** do processo de quatro passos. Siga os passos **Planeje**, **Resolva** e **Conclua** conforme ilustrado nos Exemplos 21.2 e 21.3 para testes de significância e no Exemplo 21.4 para intervalos de confiança. Lembre-se de que o exame dos dados e a discussão das condições para inferência fazem parte do passo **Resolva**.

21.47 Pensar em dinheiro muda o comportamento. Kathleen Vohs, da University of Minnesota, e seus colaboradores realizaram vários experimentos comparativos aleatorizados sobre os efeitos de se pensar em dinheiro. Eis parte de um desses experimentos.²⁵ Peça a sujeitos estudantes que desembaralhem 30 conjuntos de cinco palavras para formar uma frase com sentido a partir de quatro das cinco palavras de cada conjunto. O grupo de controle desembaralhou frases como “frio está carteira lá fora” em “está frio lá fora”. O grupo de tratamento desembaralhou frases que levavam a pensar sobre dinheiro, e “alto de salário carteira pagamento” foi transformado em “alto pagamento de salário”. Então, cada sujeito trabalhou em um difícil quebra-cabeça, sabendo que poderia pedir ajuda. Eis os tempos, em segundos, até os sujeitos pedirem ajuda. Para o grupo de tratamento:  **PENSDIN**

609	444	242	199	174	55	251	466	443
531	135	241	476	482	362	69	160	

Para o grupo de controle:

118	272	413	291	140	104	55	189	126
400	92	64	88	142	141	373	156	

Os pesquisadores suspeitavam que dinheiro estivesse ligado a autossuficiência, de modo que o grupo de tratamento iria pedir ajuda menos rapidamente, na média. Os dados corroboram essa ideia?

ESTATÍSTICA NO MUNDO REAL

O dinheiro é a raiz de todo o mal?

Isso é ir muito longe, mas Kathleen Vohs e seus colaboradores mostram que até mesmo pensar em dinheiro tem fortes efeitos. O Exercício 21.47 descreve uma pequena parte de seu trabalho. O que a Professora Vohs diz sobre as consequências de se ter dinheiro? “O dinheiro faz com que as pessoas se sintam autossuficientes e se comportem de acordo com isso.” Com dinheiro, você pode alcançar seus objetivos com menos ajuda dos outros. Você se sente menos dependente dos outros e mais desejoso de trabalhar na direção de seus objetivos. Talvez isso seja bom. Você também prefere se envolver menos com os outros, de modo que a autossuficiência é uma barreira para relações mais próximas com outras pessoas. Talvez isso não seja bom. Os cientistas não nos dizem o que é bom e o que não é, apenas que o dinheiro aumenta nossa sensação de autossuficiência.

21.48 Obesidade em adolescentes. A obesidade em adolescentes é um sério risco para a saúde e afeta mais de 5 milhões de pessoas jovens, apenas nos Estados Unidos. Bandagem gástrica ajustável por laparoscopia tem a vantagem de oferecer um tratamento seguro e eficaz. Cinquenta adolescentes com idade entre 14 e 18 anos, com índice de massa corporal superior a 35, foram recrutados na comunidade de Melbourne, Austrália, para o estudo.²⁶ Vinte e cinco foram selecionados aleatoriamente para fazerem a bandagem gástrica, e os restantes 25 foram direcionados para um programa

de intervenção no estilo de vida supervisionado, envolvendo dieta, exercício e modificação de comportamento. Todos os sujeitos foram acompanhados por dois anos. Eis as perdas de peso, em quilogramas, para os sujeitos que completaram o estudo. No grupo da bandagem gástrica:  **OBSADOL**

35,6	81,4	57,6	32,8	31,0	37,6	36,5	-5,4	27,9	49,0	64,8	39,0
43,0	33,9	29,7	20,2	15,2	41,7	53,4	13,4	24,8	19,4	32,3	22,0

No grupo da intervenção no estilo de vida:

6,0	2,0	-3,0	20,6	11,6	15,5	-17,0	1,4	4,0
-4,6	15,8	34,6	6,0	-3,1	-4,3	-16,7	-1,8	-12,8

Há boa evidência de que a bandagem gástrica leve a uma perda de peso maior do que o programa de intervenção no estilo de vida?

21.49 Dor compartilhada e vínculo. Embora experiências dolorosas estejam envolvidas em rituais sociais em muitas partes do mundo, pouco se sabe sobre os efeitos sociais da dor. Compartilhar uma experiência dolorosa em um pequeno grupo leva a maior ligação dos membros do grupo do que o compartilhamento de uma experiência semelhante não dolorosa? Cinquenta e quatro estudantes em South Wales foram divididos aleatoriamente em um grupo de dor, contendo 27 estudantes, e um grupo de não dor, contendo os restantes 27 estudantes. A dor foi induzida por tarefas. Na primeira tarefa, os estudantes submergiam suas mãos em água gelada pelo tempo possível, movendo bolas de metal no fundo da vasilha, em um recipiente submerso. Na segunda tarefa, os estudantes realizaram um agachamento com as costas retas na parede e joelhos a 90 graus pelo tempo possível. O grupo da não dor completou a primeira tarefa usando água à temperatura ambiente por 90 segundos, e a segunda tarefa equilibrando-se em um só pé por 60 segundos, trocando de pé, se necessário. Em ambos os contextos, com e sem dor, os estudantes completaram as tarefas em pequenos grupos que, tipicamente, eram compostos por quatro estudantes e tinham níveis semelhantes de interação de grupo. Depois, cada estudante respondeu a um questionário para criar um escore de vínculo, com base nas respostas a sete afirmativas, como “Eu sinto que os participantes no estudo têm muito em comum”, ou “Sinto que posso confiar nos outros participantes”. Cada resposta recebeu um escore em uma escala de cinco pontos (1 = discorda fortemente, 5 = concorda fortemente), e fez-se a média dos escores nas sete afirmativas para criar um escore de vínculo para cada sujeito. Eis os escores de vínculo para os sujeitos nos dois grupos:²⁷  **DOR**

Grupo sem dor:	3,43	4,86	1,71	1,71	3,86	3,14	4,14
	3,14	4,43	3,71	3,00	3,14	4,14	4,29
	2,43	2,71	4,43	3,43	1,29	1,29	3,00
	3,00	2,86	2,14	4,71	1,00	3,71	
Grupo com dor:	4,71	4,86	4,14	1,29	2,29	4,43	3,57
	4,43	3,57	3,43	4,14	3,86	4,57	4,57
	4,29	1,43	4,29	3,57	3,57	3,43	2,29
	4,00	4,43	4,71	4,71	2,14	3,57	

Os dados mostram que o compartilhamento de uma experiência dolorosa em um pequeno grupo leva a escores mais altos de vínculo para os membros do grupo do que o compartilhamento de uma experiência semelhante sem dor?

21.50 A cada dia melhora em matemática. Uma mensagem “subliminar” está abaixo de nosso limiar de consciência, mas, mesmo assim, pode nos influenciar. Mensagens subliminares podem ajudar os alunos a aprenderem matemática? Um grupo de alunos reprovados na parte de matemática do teste de avaliação City University of New York Skills Assessment Test concordou em participar de um estudo para descobrir isso.



Todos recebiam diariamente uma mensagem subliminar, que acendia em uma tela tão rapidamente que não podia ser conscientemente lida. O grupo de tratamento de 10 alunos (escolhidos aleatoriamente) foi exposto a “A cada dia melhora em matemática”. O grupo de controle de oito alunos foi exposto a uma mensagem neutra. “As pessoas estão andando na rua.” Todos os alunos participaram de um programa de verão planejado para elevar suas habilidades matemáticas e todos se submeteram à avaliação novamente no fim do programa. A Tabela 21.3 fornece os dados sobre os escores dos sujeitos antes e depois do programa.²⁸ Há boa evidência de que o tratamento tenha gerado melhores resultados nos escores de matemática do que a mensagem neutra? Quão grande é a diferença média nos ganhos entre os grupos de tratamento e de controle? (Use 95% de confiança.)

SUBLIM

Tabela 21.3 Escores de habilidades matemáticas antes e depois de uma mensagem subliminar

Grupo de tratamento		Grupo de controle	
Antes	Depois	Antes	Depois
18	24	18	29
18	25	24	29
21	33	20	24
18	29	18	26
18	33	24	38
20	36	22	27
23	34	15	22
23	36	19	31
21	34		
17	27		

21.51 Dor compartilhada e vínculo (continuação).

- Use os dados no Exercício 21.49 para dar um intervalo de confiança de 90% para a diferença no escore médio de vínculo nos grupos de sem dor e com dor.
- Dê um intervalo de confiança para o escore médio de vínculo dos estudantes do grupo da dor.

21.52 Flores tropicais. Diferentes variedades da flor tropical *Heliconia* são fertilizadas por diferentes espécies de beija-flores. Ao longo do tempo, os comprimentos das flores e as formas dos bicos dos beija-flores evoluíram



para se adaptarem uns aos outros. Eis os dados de comprimentos, em milímetros, de duas variedades cores da mesma espécie de flor na ilha de Dominica

FLOR



edsongrandisoli/iStock

H. caribaea vermelha

41,90	42,01	41,93	43,09	41,47	41,69	39,78	40,5
39,63	42,18	40,66	37,87	39,16	37,40	38,20	38,0
38,10	37,97	38,79	38,23	38,87	37,78	38,01	

H. caribaea amarela

36,78	37,02	36,52	36,11	36,03	35,45	38,13	37,
35,17	36,82	36,66	35,68	36,03	34,57	34,63	

Há boa evidência de que os comprimentos médios das duas variedades sejam diferentes? Estime a diferença entre as duas médias populacionais. (Use 95% de confiança.)

21.53 Estudantes que bebem. Um professor perguntou a se



estudantes de segundo ano, “Quanto drinques você bebe tipicamente por vez? [Um drink é definido como uma cerveja de 12 oz (354,88 mL), uma taça de vinho de 4 oz (118,29 mL), ou um copo de 1 oz (29,57 mL) de bebida alcoólica.]” Alguns dos estudantes não bebiam. A Tabela 21.4 dá as respostas dos estudantes mulheres e homens que bebiam.³⁰ É provável que alguns estudantes tenham exagerado um pouco. A amostra são todos os estudantes de uma grande classe de segundo ano. A classe popular, de modo que estamos tentados a considerar seus membros como uma AAS dos estudantes de segundo ano dessa faculdade. Faça uma análise completa que informe sobre

DRINKES

- o comportamento relativo à bebida relatado pelas mulheres do segundo ano.
- o comportamento relativo à bebida relatado pelos homens do segundo ano.
- uma comparação entre os comportamentos de mulheres e homens.

Tabela 21.4 Drinques por vez declarados por estudantes mulheres e homens

[illegible]